

INSTITUTO FEDERAL DO RIO GRANDE DO NORTE
CAMPUS NATAL - CENTRAL
DIRETORIA DE GESTÃO E TECNOLOGIA DA INFORMAÇÃO
TECNOLOGIA EM ANÁLISE E DESENVOLVIMENTO DE SISTEMAS

Título do trabalho

Nome completo do autor

Natal-RN

Mês (por extenso) e ano

Nome completo do autor

Título

Trabalho de conclusão de curso de graduação do curso de Tecnologia e Análise em Desenvolvimento de Sistemas da Diretoria de Gestão e Tecnologia de Informação do Instituto Federal do Rio Grande do Norte como requisito parcial para a obtenção do grau de Tecnólogo em Análise e Desenvolvimento de Sistemas.

Linha de pesquisa:

Nome da linha de pesquisa

Orientador

Nome completo do orientador e titulação

TADS – CURSO DE TECNOLOGIA EM ANÁLISE E DESENVOLVIMENTO DE SISTEMAS
DIATINF – DIRETORIA ACADÊMICA DE GESTÃO E TECNOLOGIA DA INFORMAÇÃO
CNAT – CAMPUS NATAL - CENTRAL
IFRN – INSTITUTO FEDERAL DO RIO GRANDE DO NORTE

Natal-RN

Mês e ano

Trabalho de Conclusão de Curso de Graduação sob o título *Título* apresentada por Nome completo do autor e aceita pelo Diretoria de Gestão e Tecnologia da Informação do Instituto Federal do Rio Grande do Norte, sendo aprovada por todos os membros da banca examinadora abaixo especificada:

Nome completo do orientador e titulação

Presidente

DIATINF – Diretoria Acadêmica de Gestão e Tecnologia da
Informação

IFRN – Instituto Federal do Rio Grande do Norte

Nome completo do examinador e titulação

Examinador

Diretoria/Departamento

Instituto

Nome completo do examinador e titulação

Examinador

Diretoria/Departamento

Universidade

Natal-RN, data da defesa (dia, mês e ano).

Homenagem que o autor presta a uma ou mais pessoas.

Agradecimentos

Agradecimentos dirigidos àqueles que contribuíram de maneira relevante à elaboração do trabalho, sejam eles pessoas ou mesmo organizações.

Citação

Autor

Título do trabalho

Autor: Nome do aluno

Orientador(a): Titulação e nome do(a) orientador(a)

RESUMO

O resumo deve apresentar de forma concisa os pontos relevantes de um texto, fornecendo uma visão rápida e clara do conteúdo e das conclusões do trabalho. O texto, redigido na forma impessoal do verbo, é constituído de uma sequência de frases concisas e objetivas e não de uma simples enumeração de tópicos, não ultrapassando 500 palavras, seguido, logo abaixo, das palavras representativas do conteúdo do trabalho, isto é, palavras-chave e/ou descritores. Por fim, deve-se evitar, na redação do resumo, o uso de parágrafos (em geral resumos são escritos em parágrafo único), bem como de fórmulas, diagramas e símbolos, optando-se, quando necessário, pela transcrição na forma extensa, além de não incluir citações bibliográficas.

Palavras-chave: Palavra-chave 1, Palavra-chave 2, Palavra-chave 3.

Título do trabalho (em língua estrangeira)

Author: Nome do aluno

Supervisor: Titulação e nome do(a) orientador(a)

ABSTRACT

O resumo em língua estrangeira (em inglês *Abstract*, em espanhol *Resumen*, em francês *Résumé*) é uma versão do resumo escrito na língua vernícula para idioma de divulgação internacional. Ele deve apresentar as mesmas características do anterior (incluindo as mesmas palavras, isto é, seu conteúdo não deve diferir do resumo anterior), bem como ser seguido das palavras representativas do conteúdo do trabalho, isto é, palavras-chave e/ou descritores, na língua estrangeira. Embora a especificação abaixo considere o inglês como língua estrangeira (o mais comum), não fica impedido a adoção de outras linguas (a exemplo de espanhol ou francês) para redação do resumo em língua estrangeira.

Keywords: Keyword 1, Keyword 2, Keyword 3.

Lista de figuras

Lista de tabelas

Lista de abreviaturas e siglas

Sumário

1	Introdução	p. 13
1.1	Objetivos	p. 14
1.1.1	Objetivos Gerais	p. 14
1.1.2	Objetivos Específicos	p. 14
1.2	Metodologia	p. 14
1.3	Organização do trabalho	p. 14
2	Outliers	p. 15
2.1	Algorithms	p. 15
2.1.1	Z-Score	p. 15
2.1.2	DBSCAN	p. 16
2.1.3	Isolation Forests	p. 16
2.1.4	ISODEPTH	p. 16
2.1.5	FDC	p. 16
2.1.6	HOD	p. 16
2.1.7	Nested Loop	p. 17
2.1.8	ORCA	p. 17
2.1.9	Linearization	p. 17
2.1.10	RBRP	p. 17
2.1.11	LOF	p. 18
2.1.12	INFLO	p. 18
2.1.13	LOCI	p. 18

2.1.14 ABOD	p. 18
2.1.15 SOD	p. 18
3 Considerações finais	p. 19
3.1 Principais contribuições	p. 19
3.2 Limitações	p. 19
3.3 Trabalhos futuros	p. 19
Referências	p. 20
Apêndice A – Primeiro apêndice	p. 21
Anexo A – Primeiro anexo	p. 22

1 Introdução

In the last ten years, the search for terms such as big data, data analysis, and data visualization has increased enormously. One of the reasons is that with the advancement of technology and computers, we have been able to generate huge masses of data from different sources in various formats and in an incredibly small time. Along with this came also new difficulties in the field of data analysis which is: How to process these immense quantities quickly and efficiently?

Aiming at this problem, several types of research and tools have appeared that try to solve or improve it in some way, either by proposing techniques to increase the performance of the analyzes or to perform the data cleaning or to improve the structure of how to save these data. Among these researches there is a part focused on how to visualize these large amounts of data and still more when it comes to spatial data, as it turns out to be a serious problem the more the amount of data grows, since the researcher could end up getting "lost "in the middle of so much information leaving their analysis greatly damaged.

In this context, one of these researches produced a new proposal that aims to improve the visualization and analysis of huge amounts of spatial data, the GeoGuide: a tool in which it is possible to load a generic dataset with spatial data (latitude and longitude attributes) and metadata and then visualize it on a global map to better navigate between them. Along with this there is also the concept of diversity and similarity that serves for an approach in which the researcher expands its area of research through highlights of similar points in distinct areas of a single point chosen by him. for example: Joana is a culinary enthusiast and wants to find new restaurants in neighborhoods that serve Brazilian food at a price range from 20to 100. In a few clicks, you can find these suggestions in GeoGuide.

However, a new problem arises that is the availability of Joana to be able to reach certain neighborhoods because she does not have a car and needs public transportation to transit in her city. Aiming at this new feature, GeoGuide is adding the concepts of regions of interest (neighborhoods, in the case of Joana) so that the researcher can, implicitly

(using the mouse movement), demonstrate which region is more interesting for him and thus avoid one more step that would be the process to exclude the suggestions of the GeoGuide that would be in unavailable places for Joana to access. With this concept it is also possible to solve another problem that would be the case of Marcos, who is passionate about travel and wants to redo a trip to Italy, however, he decided that he does not want to visit the same sights. So to avoid a new process, Mark would get suggestions outside his region of interest (which would be his last places visited in Italy), and then enjoy his trip.

1.1 Objetivos

Nesta seção são definidos os objetivos gerais e específicos do trabalho.

1.1.1 Objetivos Gerais

- Objetivo geral 1...
- Objetivo geral 2...

1.1.2 Objetivos Específicos

Lista de objetivos específicos do trabalho...

- Objetivo específico 1...
- Objetivo específico 2...

1.2 Metodologia

Na metodologia é descrito o método de investigação e pesquisa para o desenvolvimento e implementação do trabalho que está sendo proposto.

1.3 Organização do trabalho

Nesta seção deve ser apresentado como está organizado o trabalho, sendo descrito, portanto, do que trata cada capítulo.

2 Outliers

Outliers in the statistics area are when one finds "aberrant values" in a given series of data, that is when one finds an atypical value or with a great distance from the normal distribution in that set. For example, when a researcher wants to monitor the temperature of his CPU during a certain time interval and it has been realized that the average temperature range is between 34 °C and 48 °C degrees being 45 °C the maximum temperature and 27 °C the minimum temperature and in the middle of this sample are some punctual registers of 0 °C, this can be characterized as an outlier and, most likely, will be understood as a malfunction of the equipment that performed the collection of these CPU temperatures.

However, there are several ways to interpret an Outlier (not only as a collection error), but also as: data that belong to a different population of the sample, a damaged data, areas in which a certain theory is not valid or even, when the sample is too large, it is normal to have some small amounts of outliers in that group. In cases where it is proven that it is not the fault of a collection equipment malfunction or that it was not a human mistake, it is extremely important to know the why of that outlier and try to understand it, because it is not interesting for a research simply remove it from the sample or re-signify it by assigning a new value. This change may compromise the validity of the research, and if this is done, it is extremely important to document and record those changes.

2.1 Algorithms

2.1.1 Z-Score

Z-Score is one of the simplest methods for detecting outliers in a dataset. It is a parametric method and takes into account only one attribute per execution. It is also necessary the input of a threshold (usually is a value between 2.5 to 3.5) to be able to define if a given data can be considered an outlier or not. This method is suitable for

small datasets that follow the Gaussian distribution.

2.1.2 DBSCAN

It is a density-based spatial clustering algorithm that can be applied in datasets that cannot be presumed what their distribution. It accepts multidimensional datasets (with 3 or more dimensions). However, you need a parameter (MinPts) that defines how many minimum points are needed to form a cluster. Thus, if the size of the set change, this parameter will need to be updated, otherwise the DBSCAN can become inefficient.

2.1.3 Isolation Forests

It is an algorithm of detection of outliers that uses a concept of machine learning that is the decision tree. It is one-dimensional (only takes one attribute at a time) and is required few parameters (this facilitates the configuration and use of the algorithm). No need to climb your values and a very robust algorithm for large datasets.

2.1.4 ISODEPTH

...

2.1.5 FDC

It is a depth-based algorithm approach for detection of outliers in 2D datasets based on the concept of ISODEPTH algorithm. The FDC computes the first k 2D depth contours (the points that can be considered outliers) by restricting to a small part of the complete dataset. In this way, it is more efficient by not having to calculate in the complete dataset and thus scaling more easily for large datasets of two dimensions.

2.1.6 HOD

It is a distance-based outlier detection method that emerges to overcome the statistics-based concept because in the vast majority of datasets the probability distribution is not known. In this way, the method search for outliers based on their distance from their neighbors and if that point has a distance greater than a predefined parameter, then that point is considered an outlier. However, if there is a cluster of outliers in the dataset,

this can affect its detection by distance-based algorithms, with this comes the concept of HOD (Hidden Outlier Detection) algorithms that aim to find outliers even when they are grouped and in enough quantity to form a cluster.

2.1.7 Nested Loop

...

2.1.8 ORCA

It is a distance-based algorithm that optimizes a simple nested loop algorithm (which are logarithmic algorithms and extremely inefficient when dealing with large datasets) by removing possible non-outliers during their execution. This way, instead of processing the complete dataset by calculating all possible distances, it removes unnecessary calculations that would be executed if a non-outlier point were taken to the end. From him, new researches have emerged further refining this concept.

2.1.9 Linearization

It is a distance-based algorithm that detects outliers by calculating the sum of the distances of a point in relation to its neighbor, calling it weight, and setting an outlier as the points with the greatest weights in the dataset. In this way, it is an efficient algorithm and it is linearly scaled both in the number of points and in the number of dimensions. To calculate these outliers more efficiently the algorithm uses the concept of the Hilbert space filling curve.

2.1.10 RBRP

It is an algorithm for high performance multidimensional datasets that is based on distances between the points to be able to define what the outliers are. Its difference to the other distance-based algorithms is that it is more efficient for datasets with multiple dimensions and in comparisons with others, its scalability is approximately linear for the number of dimensions and logarithmic for the number of points in the dataset.

2.1.11 LOF

It is a Density-based algorithm that adds a new concept in the search for outliers: the Local Outlier Factor (LOF), which is a degree of propensity to be an outlier so that the process of outlier definition is not more binary, but something gradual. With this, the approach is not to define whether a point is an outlier or not, but rather the "how outlier" that point is in that dataset. The outlier factor is local in the sense that only a neighborhood of that point is taken into account to define its factor.

2.1.12 INFLO

2.1.13 LOCI

2.1.14 ABOD

It is an angle-based algorithm for detection of outliers that is focused on high-dimensional datasets, different from other distance-based algorithms that end up damaged when one has many dimensions. Your approach is based on the calculation of a degree of angle between the different vectors of a point with its neighbors. With this, more centralized points within the cluster will have this degree calculated with a high value, the points more on the edge of the clusters will have this degree a little smaller and the possible outliers will have that degree with a very small value, since they will generally be far from the cluster in a particular direction.

2.1.15 SOD

3 Considerações finais

As considerações finais formam a parte final (fechamento) do texto, sendo dito de forma resumida (1) o que foi desenvolvido no presente trabalho e quais os resultados do mesmo, (2) o que se pôde concluir após o desenvolvimento bem como as principais contribuições do trabalho, e (3) perspectivas para o desenvolvimento de trabalhos futuros, como listado nos exemplos de seção abaixo. O texto referente às considerações finais do autor deve salientar a extensão e os resultados da contribuição do trabalho e os argumentos utilizados estar baseados em dados comprovados e fundamentados nos resultados e na discussão do texto, contendo deduções lógicas correspondentes aos objetivos do trabalho, propostos inicialmente.

3.1 Principais contribuições

Texto.

3.2 Limitações

Texto.

3.3 Trabalhos futuros

Texto.

Referências

APÊNDICE A – Primeiro apêndice

Os apêndices são textos ou documentos elaborados pelo autor, a fim de complementar sua argumentação, sem prejuízo da unidade nuclear do trabalho.

ANEXO A – Primeiro anexo

Os anexos são textos ou documentos não elaborado pelo autor, que servem de fundamentação, comprovação e ilustração.